



Departemen Teknik Informatika



www.its.ac.id



[its_campus](#)




[institut teknologi sepuluh nopember](#)



Principal Component Analysis (PCA)

- Transformasi data ke representasi baru dengan cara menemukan proyeksi yang menangkap variasi data terbesar
- Data asli diproyeksikan ke dimensi yang lebih kecil sehingga mengurangi ukuran dimensi.
- Mendapatkan vektor eigen dari matriks kovarians, dan vektor eigen ini digunakan untuk memproyeksikan data asli ke dimensi baru





Principal components

- Principal component 1 (PC1)
 - The eigenvalue with the largest absolute value will indicate that the data have the largest variance along its eigenvector, the direction along which there is greatest variation
- Principal component 2 (PC2)
 - the direction with maximum variation left in data, orthogonal to the PC1
- In general, only few directions manage to capture most of the variability in the data.



Tahapan PCA

- Input: Vektor data X dengan n -dimensi
- Tujuan: Mencari p komponen utama ($p \leq n$) yang paling baik untuk merepresentasikan data
- Tahapan:
 - Hitung \bar{X} sebagai nilai rata-rata setiap fitur
 - Hitung data orisinal X dikurangi nilai rata-rata \bar{X}
 $X' = X - \bar{X}$
 - Hitung *Covariance matrix* C dari X'
 - Hitung *eigenvectors* dan *eigenvalues* dari C
 - *eigenvectors* dari C adalah \mathbf{e} sedemikian hingga $C\mathbf{e} = \lambda\mathbf{e}$,
 - λ adalah *eigenvalue* dari C
 - $C\mathbf{e} = \lambda\mathbf{e} \Leftrightarrow (C - \lambda I)\mathbf{e} = 0$
 - Memilih p eigenvectors dengan eigenvalues terbesar
 - Transformasi data asli dengan cara mengalikan matrik X' dengan p eigenvectors



$$\begin{pmatrix} y_{i1} \\ y_{i2} \\ \dots \\ y_{ip} \end{pmatrix} = \begin{pmatrix} e_1 \\ e_2 \\ \dots \\ e_p \end{pmatrix} \begin{pmatrix} x_{i1} - \bar{x}_1 \\ x_{i2} - \bar{x}_2 \\ \dots \\ x_{in} - \bar{x}_n \end{pmatrix}$$



Contoh Penerapan PCA

X1	X2	X1'	X2'
19	63	-5.1	9.25
39	74	14.9	20.25
30	87	5.9	33.25
30	23	5.9	-30.75
15	35	-9.1	-18.75
15	43	-9.1	-10.75
15	32	-9.1	-21.75
30	73	5.9	19.25

Mean X1=24.1
Mean X2=53.8





Covariance Matrix

Bagaimana menghitung **e** dan λ :

- Hitung $\det(C-\lambda I)$
- Temukan akar $\det(C-\lambda I)=0$, nilai akar \rightarrow eigenvalues λ
- Selesaikan $(C-\lambda I) \mathbf{e} = 0$ pada setiap λ utk memperoleh eigenvectors **e**

- $C = \begin{bmatrix} 75 & 106 \\ 106 & 482 \end{bmatrix}$

Covariance Matrix dengan 3 fitur

$$C = \begin{pmatrix} \text{cov}(x, x) & \text{cov}(x, y) & \text{cov}(x, z) \\ \text{cov}(y, x) & \text{cov}(y, y) & \text{cov}(y, z) \\ \text{cov}(z, x) & \text{cov}(z, y) & \text{cov}(z, z) \end{pmatrix}$$

$$\text{cov}(X, Y) = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{(n-1)}$$


- Eigenvectors:
 - $\mathbf{e1}=(-0.98,-0.21)$, $\lambda_1=51.8$
 - $\mathbf{e2}=(0.21,-0.98)$, $\lambda_2=560.2$
- *Eigenvector* kedua $\mathbf{e2}$ paling penting!



PCA dengan 1 PC (Principle Component)

X1	X2	X1'	X2'
19	63	-5.1	9.25
39	74	14.9	20.25
30	87	5.9	33.25
30	23	5.9	-30.75
15	35	-9.1	-18.75
15	43	-9.1	-10.75
15	32	-9.1	-21.75
30	73	5.9	19.25

- Menggunakan $e_2=(0.21,-0.98)$
- Transformasi data yang didapatkan sbb:



y_i
-10.14
-16.72
-31.35
31.374
16.464
8.624
19.404
-17.63


$$\begin{pmatrix} y_{i1} \\ y_{i2} \\ \dots \\ y_{ip} \end{pmatrix} = \begin{pmatrix} e_1 \\ e_2 \\ \dots \\ e_p \end{pmatrix} \begin{pmatrix} x_{i1} - \bar{x}_1 \\ x_{i2} - \bar{x}_2 \\ \dots \\ x_{in} - \bar{x}_n \end{pmatrix}$$

$$y_i = (0.21 \quad -0.98) \begin{pmatrix} x_{i1} \\ x_{i2} \end{pmatrix} = 0.21 * x_{i1} - 0.98 * x_{i2}$$



PCA pada Leukemia data dengan 100 genes serta 2 precursor B dan T

Data 34 pasien, dimensi dari 100 genes menjadi 2





PCA pada Citra Wajah





Singular Value Decomposition (SVD)

$$\mathbf{A}_{[n \times m]} = \mathbf{U}_{[n \times r]} \mathbf{\Lambda}_{[r \times r]} (\mathbf{V}_{[m \times r]})^T$$

- **SVD** : metode dekomposisi sebuah matrik menjadi 3 matrik
- **A**: $n \times m$ matrik (contoh: n dokumen, m kata)
- **U**: $n \times r$ matrik orthogonal (contoh: n dokumen, r konsep)
- **Λ** : $r \times r$ matrik diagonal (r : rank dari matrik)
- **V**: $m \times r$ matrik orthogonal (contoh: m kata, r konsep)



SVD Properties

THEOREM [Press+92]: always possible to decompose matrix \mathbf{A} into $\mathbf{A} = \mathbf{U} \mathbf{\Lambda} \mathbf{V}^T$, where:

- \mathbf{U} , $\mathbf{\Lambda}$, \mathbf{V} : unique
- \mathbf{U} , \mathbf{V} : column orthonormal (orthogonal to each other)
 - $\mathbf{U}^T \mathbf{U} = \mathbf{I}$; $\mathbf{V}^T \mathbf{V} = \mathbf{I}$ (\mathbf{I} : identity matrix)
- $\mathbf{\Lambda}$: singular value are positive, and sorted in decreasing order

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 2 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 3 & 3 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} | & | \\ \mathbf{u}_1 & \mathbf{u}_2 \\ | & | \end{bmatrix} \times \begin{bmatrix} \lambda_1 & \emptyset \\ \emptyset & \lambda_2 \end{bmatrix} \times \begin{bmatrix} \text{---} & \mathbf{v}_1 & \text{---} \\ \text{---} & \mathbf{v}_2 & \text{---} \end{bmatrix}$$



Contoh Penerapan SVD

	term	data	information	retrieval	brain	lung
document						
CS-TR1		1	1	1	0	0
CS-TR2		2	2	2	0	0
CS-TR3		1	1	1	0	0
CS-TR4		5	5	5	0	0
MED-TR1		0	0	0	2	2
MED-TR2		0	0	0	3	3
MED-TR3		0	0	0	1	1

Tugas:

#1: Menemukan konsep pada teks

#2: Mengurangi dimensi




$$A = \begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 2 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 3 & 3 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix}$$



$$A = U \Lambda V^T$$

Contoh Penerapan SVD

#1:
Menemukan
konsep pada teks





Contoh Penerapan SVD

#2:
Mengurangi dimensi

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 2 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 3 & 3 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 0.18 & 0 \\ 0.36 & 0 \\ 0.18 & 0 \\ 0.90 & 0 \\ 0 & 0.53 \\ 0 & 0.80 \\ 0 & 0.27 \end{bmatrix} \times \begin{bmatrix} 9.64 & 0 \\ 0 & 5.29 \end{bmatrix} \times \begin{bmatrix} 0.58 & 0.58 & 0.58 & 0 & 0 \\ 0 & 0 & 0 & 0.71 & 0.71 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 2 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 3 & 3 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix} \sim \begin{bmatrix} 0.18 \\ 0.36 \\ 0.18 \\ 0.90 \\ 0 \\ 0 \\ 0 \end{bmatrix} \times \begin{bmatrix} 9.64 \end{bmatrix} \times \begin{bmatrix} 0.58 & 0.58 & 0.58 & 0 & 0 \end{bmatrix}$$



Contoh Penerapan SVD

$$\begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 2 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 2 & 2 \\ 0 & 0 & 0 & 3 & 3 \\ 0 & 0 & 0 & 1 & 1 \end{bmatrix} \sim \begin{bmatrix} 1 & 1 & 1 & 0 & 0 \\ 2 & 2 & 2 & 0 & 0 \\ 1 & 1 & 1 & 0 & 0 \\ 5 & 5 & 5 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

#2:
Mengurangi
dimensi



SVD Step

- https://web.mit.edu/be.400/www/SVD/Singular_Value_Decomposition.htm



Referensi

- *C. Faloutsos*, "Powerful tools for Data Mining fractals, power laws, SVD", Carnegie Mellon University, 2004.
- *Jure Leskovec*, "Dimensionality reduction: PCA, SVD, MDS, ICA, and friends", Machine Learning recitation, 2006.